МІНІСТЕРСТВО ОСВІТИ І НАУКИ, МОЛОДІ ТА СПОРТУ УКРАЇНИ
НАЦІОНАЛЬНИЙ ТЕХНІЧНИЙ УНІВЕРСИТЕТ УКРАЇНИ
«КИЇВСЬКИЙ ПОЛІТЕХНІЧНИЙ ІНСТИТУТ»
ФІЗИКО-ТЕХНІЧНИЙ ІНСТИТУТ

КРИПТОГРАФІЯ

КОМП’ЮТЕРНИЙ ПРАКТИКУМ №1

«Експериментальна оцінка ентропії на символ джерела відкритого тексту»

Виконали:

Студенти групи 3 курсу
груп ФБ-96 та ФБ-94
Ігнатенко Артем
Васюченко Георгій

Київ 2021

Мета:
Засвоєння понять ентропії на символ джерела та його надлишковості, вивчення та порівняння різних моделей джерела відкритого тексту для наближеного визначення ентропії, набуття практичних навичок щодо оцінки ентропії на символ джерела.

Постановка задачі:
0. Уважно прочитати методичні вказівки до виконання комп'ютерного практикуму.
1. Написати програми для підрахунку частот букв і частот біграм в тексті, а також підрахунку 1 H та 2 H за безпосереднім означенням. Підрахувати частоти букв та біграм, а також значення 1 H та 2 H на довільно обраному тексті російською мовою достатньої довжини (щонайменше 1Мб), де ймовірності замінити відповідними частотами. Також одержати значення 1 H та 2 H на тому ж тексті, в якому вилучено всі пробіли.
2. За допомогою програми CoolPinkProgram оцінити значення (10) H , (20) H , (30) H .
3. Використовуючи отримані значення ентропії, оцінити надлишковість російської мови в різних моделях джерела.

Хід роботи:

Використані формули:
Ентропія

$$H(Z) = -\sum_{i=1}^{n} p_i \log p_i \ .$$

```
def H(freq, n):
    temp = []
    for f in freq.values():
        temp.append(f * math.log(f, 2))
    temp = sorted(temp)
    H = -sum(temp) / n
    return H
```

Надлишковість

$$R = 1 - \frac{H_\infty}{H_0}$$

$$H_0 = \log_2 m \ .$$

```python
def R(value):
    R_ = 1 - value / math.log(33, 2)
    print(R_)
    return (R_)
```

Задача 1:

Частота монограм без пробілів	Частота монограм з пробілами

1	frequency_without_spaces	
2	о	0,11459
3	е	0,08699
4	а	0,07957
5	н	0,06501
6	и	0,06477
7	т	0,06468
8	с	0,05287
9	в	0,04621
10	л	0,04591
11	р	0,04178
12	к	0,03299
13	д	0,03198
14	м	0,0314
15	у	0,02962
16	п	0,02741
17	ь	0,02296
18	я	0,02134
19	ч	0,01808
20	б	0,01737
21	г	0,01687
22	ы	0,01649
23	з	0,01538
24	ж	0,0114
25	й	0,01
26	х	0,0085
27	ш	0,00822
28	ю	0,00561
29	э	0,00352
30	щ	0,00299
31	ц	0,00277
32	ф	0,00124
33	ъ	0,00024

1	frequency_with_spaces	
2		0,173396
3	о	0,094724
4	е	0,071907
5	а	0,065772
6	н	0,053739
7	и	0,053542
8	т	0,053463
9	с	0,043703
10	в	0,038196
11	л	0,037949
12	р	0,034539
13	к	0,027269
14	д	0,026436
15	м	0,025959
16	у	0,024483
17	п	0,022658
18	ь	0,018978
19	я	0,01764
20	ч	0,014947
21	б	0,014357
22	г	0,013946
23	ы	0,013635
24	з	0,012713
25	ж	0,00942
26	й	0,008268
27	х	0,007025
28	ш	0,006796
29	ю	0,004638
30	э	0,002912
31	щ	0,002469
32	ц	0,002289
33	ф	0,001027
34	ъ	0,0002

Частота біграм без пробілів

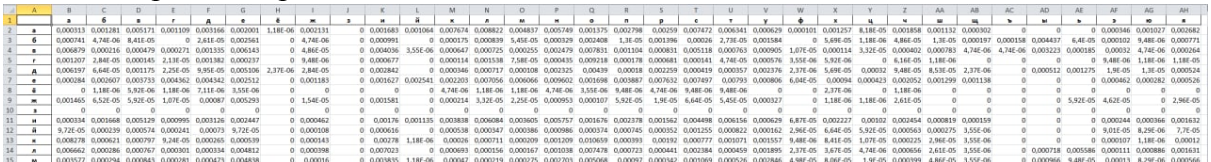

Частота біграм з пробілами

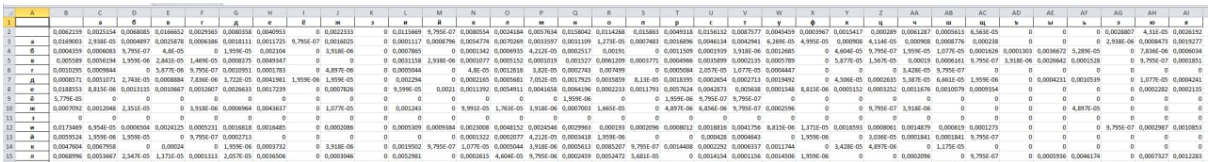

Частота біграм без пробілів, крок 2

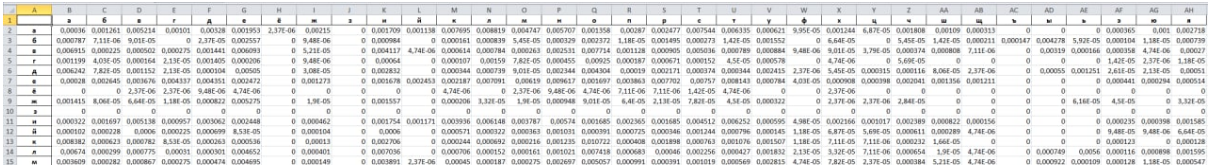

Частота біграм з пробілами, крок 2

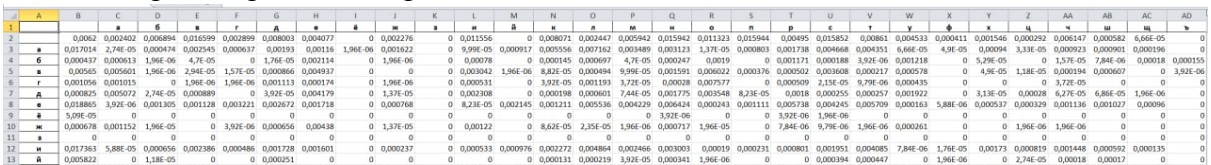

Діаграми також є в .xlsx файлах з кращою якістю зображення.

Загальна табличка із обчисленими значеннями ентропій і надлишковості для всіх експериментів.

Монограми	Монограми з пробілами	Біграми	Біграми, крок 2	Біграми з пробілами	Біграми з пробілами, крок 2
H: 4.4639485564715 R: 0.1150674489646	H: 4.3553314425284 R: 0.1365996907707	H: 4.1347527462766 R: 0.1803271813340	H: 4.1343524619426 R: 0.1804065336456	H: 3.9532759574148 R: 0.2163031151266	H: 3.9527581850499 R: 0.2164057582493

Задача 2:

H(10)

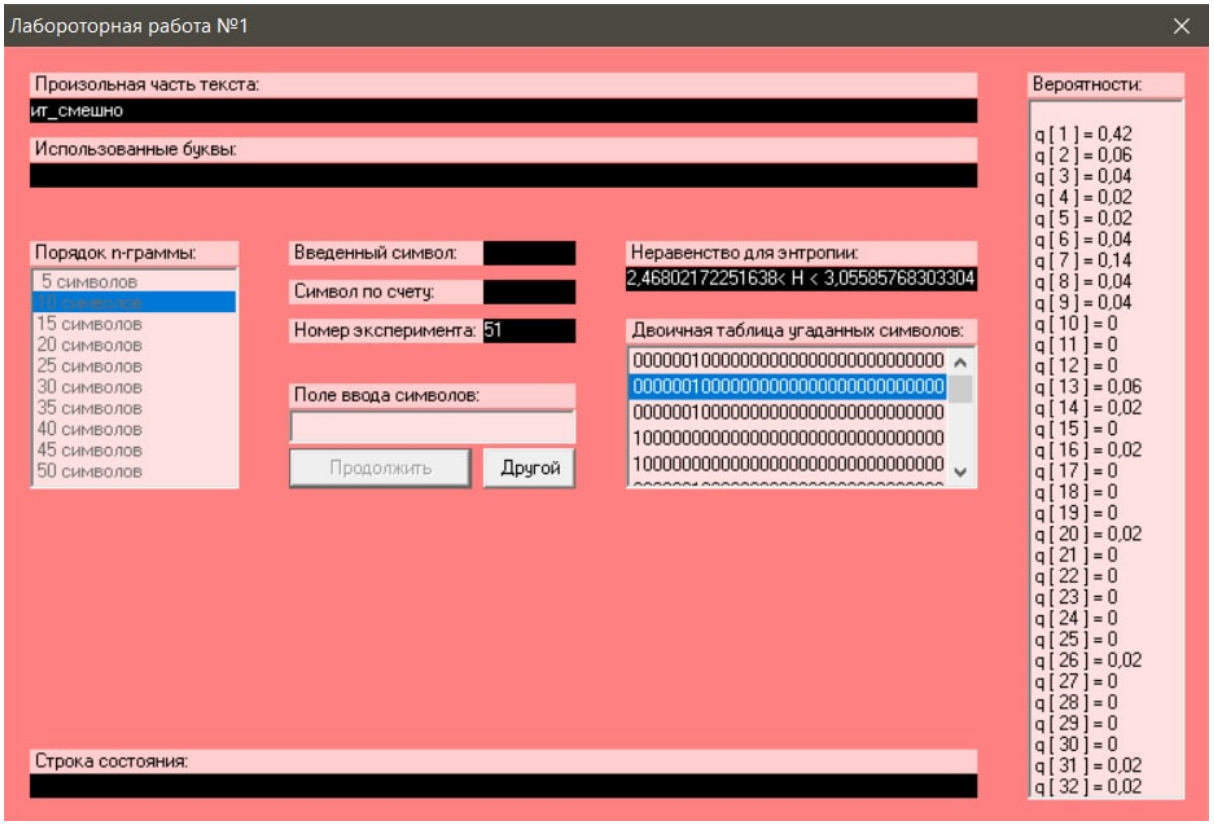

H(20)

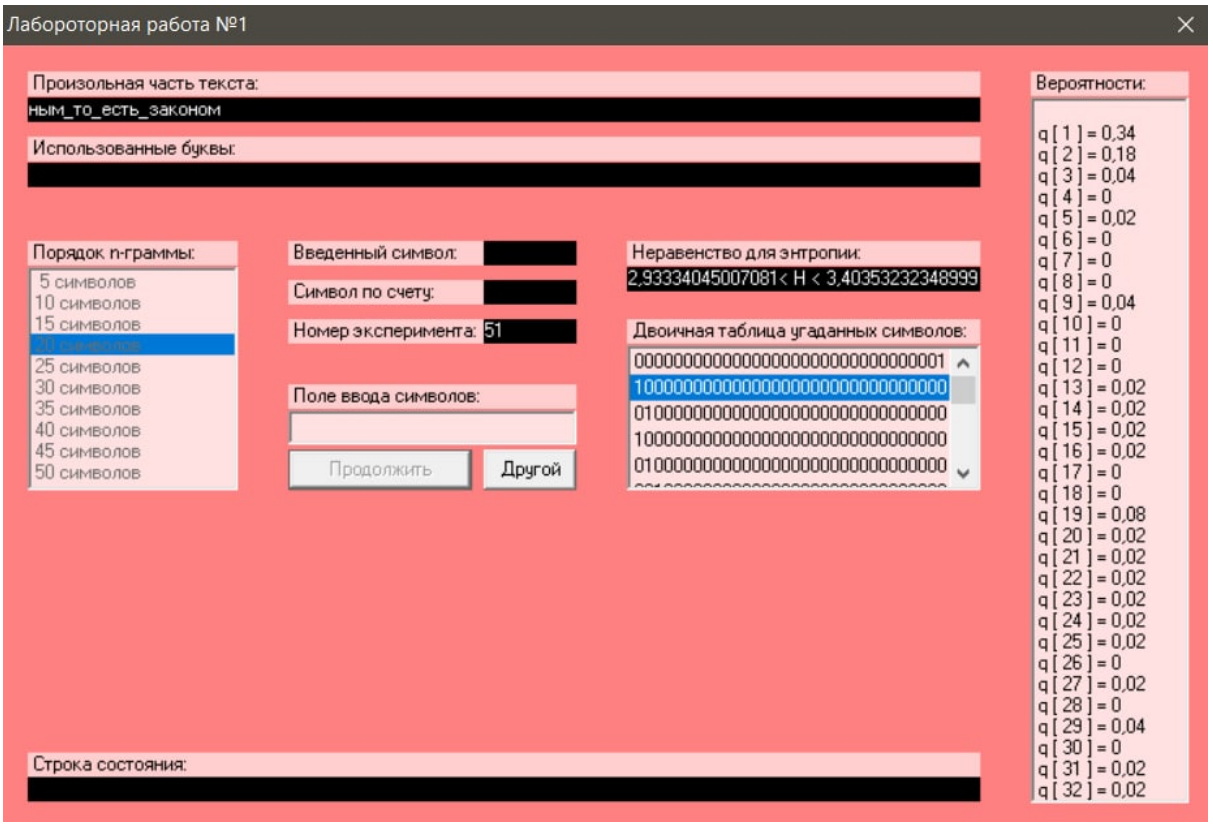
Лабороторная работа №1
Произольная часть текста:
ным_то_есть_законом
Использованные буквы:
Порядок n-граммы:
5 символов
10 символов
15 символов
20 символов
25 символов
30 символов
35 символов
40 символов
45 символов
50 символов
Введенный символ:
Символ по счету:
Номер эксперимента: 51
Поле ввода символов:
Продолжить
Другой
Неравенство для энтропии:
2,93334045007081< H < 3,40353232348999
Двоичная таблица угаданных символов:
00000000000000000000000000000001
10000000000000000000000000000000
01000000000000000000000000000000
10000000000000000000000000000000
01000000000000000000000000000000
Строка состояния:
Вероятности:
q [1] = 0,34
q [2] = 0,18
q [3] = 0,04
q [4] = 0
q [5] = 0,02
q [6] = 0
q [7] = 0
q [8] = 0
q [9] = 0,04
q [10] = 0
q [11] = 0
q [12] = 0
q [13] = 0,02
q [14] = 0,02
q [15] = 0,02
q [16] = 0,02
q [17] = 0
q [18] = 0
q [19] = 0,08
q [20] = 0,02
q [21] = 0,02
q [22] = 0,02
q [23] = 0,02
q [24] = 0,02
q [25] = 0,02
q [26] = 0
q [27] = 0,02
q [28] = 0
q [29] = 0,04
q [30] = 0
q [31] = 0,02
q [32] = 0,02

H(30)

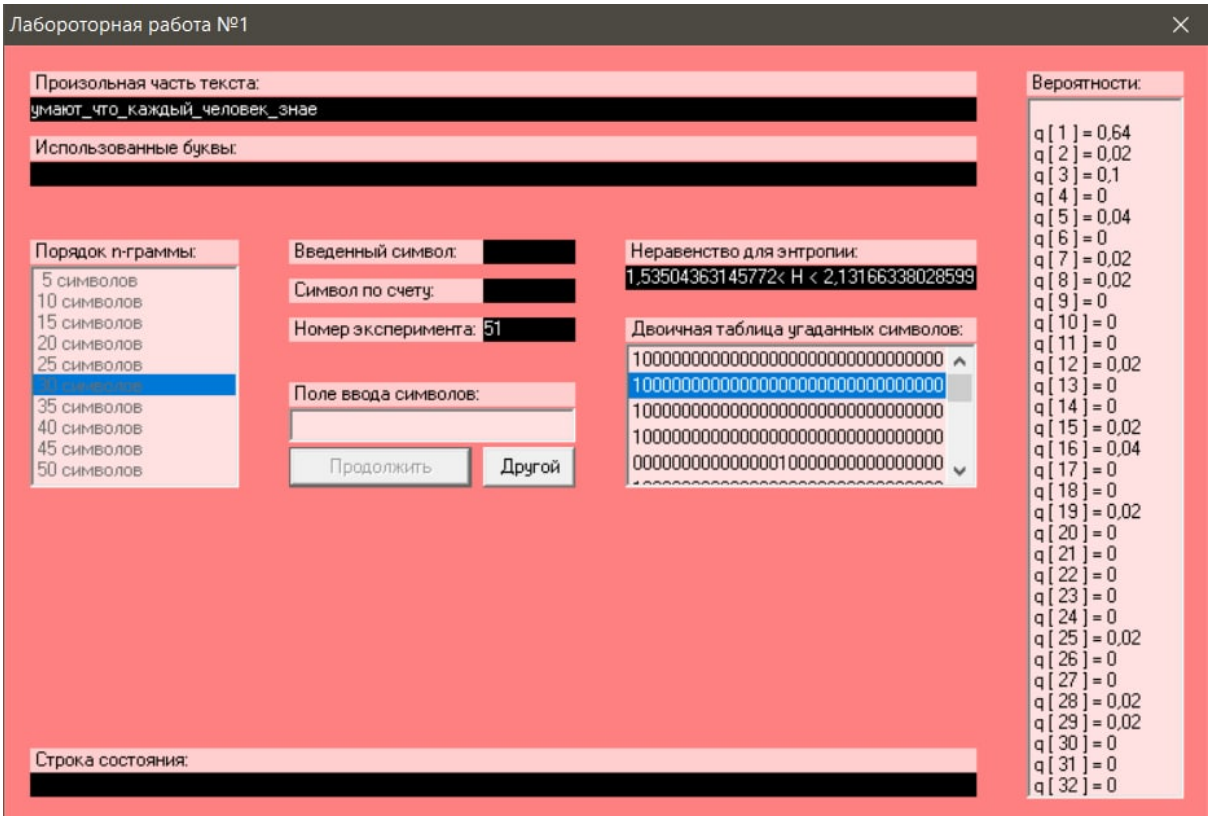
Лабороторная работа №1
Произольная часть текста:
умают_что_каждый_человек_знае
Использованные буквы:
Порядок n-граммы:
5 символов
10 символов
15 символов
20 символов
25 символов
30 символов
35 символов
40 символов
45 символов
50 символов
Введенный символ:
Символ по счету:
Номер эксперимента: 51
Поле ввода символов:
Продолжить
Другой
Неравенство для энтропии:
1,53504363145772< H < 2,13166338028599
Двоичная таблица угаданных символов:
10000000000000000000000000000000
10000000000000000000000000000000
10000000000000000000000000000000
10000000000000000000000000000000
00000000000000010000000000000000
Строка состояния:
Вероятности:
q [1] = 0,64
q [2] = 0,02
q [3] = 0,1
q [4] = 0
q [5] = 0,04
q [6] = 0
q [7] = 0,02
q [8] = 0,02
q [9] = 0
q [10] = 0
q [11] = 0
q [12] = 0,02
q [13] = 0
q [14] = 0
q [15] = 0,02
q [16] = 0,04
q [17] = 0
q [18] = 0
q [19] = 0,02
q [20] = 0
q [21] = 0
q [22] = 0
q [23] = 0
q [24] = 0
q [25] = 0,02
q [26] = 0
q [27] = 0
q [28] = 0,02
q [29] = 0,02
q [30] = 0
q [31] = 0
q [32] = 0

Задача 3:

$2.468021 < H(10) < 3.055857$	$0.510739 > R(10) > 0.394207$
$2.933340 < H(20) < 3.403532$	$0.418495 > R(20) > 0.325284$
$1.535043 < H(30) < 2.131663$	$0.695693 > R(30) > 0.577419$

Висновки:
Здобуто навички вимірювання частот повторювання різних символів в довільному тексті, оцінки ентропії, надлишковості на прикладі російської мови, підрахування частот монограм та біграм у довільному тексті.